

# Analiza czynników wpływających na choroby serca i budowa modelu predykcyjnego.

Katarzyna Krygier, Aleksandra Litewka, Karol Strzępek

Politechnika Krakowska

styczeń 2026

# Cel i problem badawczy

## Cel

Stworzenie modelu pozwalającego ocenić ryzyko wystąpienia choroby serca na podstawie parametrów klinicznych oraz klasyfikacja pacjentów pod kątem obecności choroby serca (*Presence/Absence*).

## Problem

Czy na podstawie nieinwazyjnych badań (np. EKG, poziom cholesterolu, ciśnienie) można skutecznie diagnozować choroby serca? Podejście: Zastosowanie modelu klasyfikacyjnego (regresja) oraz weryfikacja jego skuteczności poprzez wielokrotną symulację (Monte Carlo).

# Charakterystyka Zbioru Danych

| Age              | Sex             | Chest pain type | BP            | Cholesterol              | FBS over 120   | EKG results   |
|------------------|-----------------|-----------------|---------------|--------------------------|----------------|---------------|
| Min. :29.00      | Min. :0.0000    | Min. :1.000     | Min. :94.0    | Min. :126.0              | Min. :0.0000   | Min. :0.000   |
| 1st Qu.:48.00    | 1st Qu.:0.0000  | 1st Qu.:3.000   | 1st Qu.:120.0 | 1st Qu.:213.0            | 1st Qu.:0.0000 | 1st Qu.:0.000 |
| Median :55.00    | Median :1.0000  | Median :3.000   | Median :130.0 | Median :245.0            | Median :0.0000 | Median :2.000 |
| Mean :54.43      | Mean :0.6778    | Mean :3.174     | Mean :131.3   | Mean :249.7              | Mean :0.1481   | Mean :1.022   |
| 3rd Qu.:61.00    | 3rd Qu.:1.0000  | 3rd Qu.:4.000   | 3rd Qu.:140.0 | 3rd Qu.:280.0            | 3rd Qu.:0.0000 | 3rd Qu.:2.000 |
| Max. :77.00      | Max. :1.0000    | Max. :4.000     | Max. :200.0   | Max. :564.0              | Max. :1.0000   | Max. :2.000   |
| Max HR           | Exercise angina | ST depression   | Slope of ST   | Number of vessels fluoro | Thallium       |               |
| Min. :71.0       | Min. :0.0000    | Min. :0.00      | Min. :1.000   | Min. :0.0000             | Min. :3.000    |               |
| 1st Qu.:133.0    | 1st Qu.:0.0000  | 1st Qu.:0.00    | 1st Qu.:1.000 | 1st Qu.:0.0000           | 1st Qu.:3.000  |               |
| Median :153.5    | Median :0.0000  | Median :0.80    | Median :2.000 | Median :0.0000           | Median :3.000  |               |
| Mean :149.7      | Mean :0.3296    | Mean :1.05      | Mean :1.585   | Mean :0.6704             | Mean :4.696    |               |
| 3rd Qu.:166.0    | 3rd Qu.:1.0000  | 3rd Qu.:1.60    | 3rd Qu.:2.000 | 3rd Qu.:1.0000           | 3rd Qu.:7.000  |               |
| Max. :202.0      | Max. :1.0000    | Max. :6.20      | Max. :3.000   | Max. :3.0000             | Max. :7.000    |               |
| Heart Disease    |                 |                 |               |                          |                |               |
| Length:270       |                 |                 |               |                          |                |               |
| Class :character |                 |                 |               |                          |                |               |
| Mode :character  |                 |                 |               |                          |                |               |

## Rysunek: Przegląd danych

# Charakterystyka Zbioru Danych

## Liczba zmiennych

270 obserwacji, 14 (13 objaśniających + 1 wynikowa)


## Zmienna objaśniana (Y)

Heart Disease (Presence/Absence) – zmienna binarna

## Kluczowe zmienne objaśniające (X)

- 1 Wiek (Age) i Płeć (Sex)
- 2 Chest Pain Type: Typ bólu w klatce piersiowej (skala 1-4)
- 3 BP: Ciśnienie krwi spoczynkowe
- 4 Cholesterol: Poziom cholesterolu w surowicy
- 5 EKG results: Wyniki elektrokardiogramu (0-2)
- 6 Max HR: Maksymalne tętno osiągnięte podczas wysiłku
- 7 Thallium: Wynik testu talowego

# Macierz korelacji



Rysunek: Macierz korelacji

W macierzy znajdują się tylko i wyłącznie ciągłe zmienne (tylko takie można w niej uwzględnić).

## Przygotowanie danych

Wczytanie bibliotek tidyverse, caret, ggcorrplot. Analiza korelacji między zmiennymi.

## Modelowanie

Zastosowanie algorytmu uczenia nadzorowanego (klasyfikacja).

## Walidacja (Kluczowy element projektu)

- 1 Zamiast pojedynczego podziału na zbiór treningowy/testowy, zastosowano Symulację Monte Carlo (100 powtórzeń).
- 2 Pojedynczy podział może być obciążony błędem losowym. Uśrednienie wyników ze 100 prób daje wiarygodny obraz skuteczności modelu.

Zanim model został wytrenowany, przeprowadzono proces *Data Wrangling*:

## Transformacja zmiennych

- Sprawdzenie braków danych: `colSums(is.na(data))` → 0 braków.
- Faktoryzacja zmiennych jakościowych: Sex, Chest pain type, Fbs, EKG, Slope, Thallium.
- Kodowanie zmiennej celu:

$$Y = \begin{cases} 1 & \text{jeśli Heart Disease} = \text{'Presence'} \\ 0 & \text{jeśli Heart Disease} = \text{'Absence'} \end{cases}$$

## Dokładność

- 1 ok. 83-84% (średnia z 100 prób)
- 2 Interpretacja: Model poprawnie klasyfikuje ponad 8 na 10 pacjentów.

## Stabilność

Niskie odchylenie standardowe sugeruje, że model jest stabilny i nie zależy od losowego doboru danych.

## Czułość

- 1 ok. 76%
- 2 Definicja: Zdolność do wykrywania osób chorych.

## Swoistość

- 1 ok. 90%
- 2 Definicja: Zdolność do poprawnego wykluczania choroby u osób zdrowych.

## Wnioski

Model lepiej radzi sobie z potwierdzaniem zdrowia (swoistość) niż z wykrywaniem wszystkich przypadków choroby (czułość).

# Analiza Błędów (Macierz Pomyłek)

## Suma błędów w symulacji (100 prób)

- ❶ False Negative (Przeoczenie choroby): 625 przypadków
- ❷ False Positive (Fałszywy alarm): 440 przypadków

## Interpretacja kliniczna

- ❶ Liczba przeoczeń jest wyższa niż fałszywych alarmów
- ❷ Model jest "konserwatywny" – ma tendencję do uznawania pacjenta za zdrowego, gdy nie ma wysokiej pewności co do choroby
- ❸ Ryzyko: W medycynie błąd FN (nieleczony chory) jest groźniejszy niż FP (dodatkowe badania zdrowego)

# Weryfikacja współliniowości (Multicollinearity)

Zastosowano macierz korelacji Pearsona, aby uniknąć redundancji cech:

$$\rho_{X,Y} = \frac{\text{cov}(X, Y)}{\sigma_X \sigma_Y}$$

## Wnioski z analizy `ggcorrplot`:

- Większość cech wykazuje słabą lub umiarkowaną korelację.
- Najsilniejsze zależności zaobserwowano między *ST depression* a *Slope of ST*.
- Brak współczynników  $> 0.7$  pozwala na bezpieczne użycie wszystkich zmiennych w modelu regresji.


**Model matematyczny:** Stosujemy funkcję logitową:

$$\ln\left(\frac{p}{1-p}\right) = \beta_0 + \sum_{i=1}^k \beta_i X_i$$

Gdzie  $p = P(Y = 1|X)$ .

**Walidacja (100 iteracji):** Zamiast jednego podziału, zastosowano pętlę for:

- Podział 75% / 25%.
- Trening: `glm(family = "binomial")`.
- Agregacja wyników z 100 różnych losowań.



Rysunek: Histogram dla głównej miary

# Zbiorcze wyniki klasyfikacji

Suma macierzy pomyłek z 100 symulacji:

|                  | Pred: Absence      | Pred: Presence     |
|------------------|--------------------|--------------------|
| Actual: Absence  | 3435 ( <i>TN</i> ) | 440 ( <i>FP</i> )  |
| Actual: Presence | 625 ( <i>FN</i> )  | 2266 ( <i>TP</i> ) |

## Statystyki uśrednione

- **Accuracy (Dokładność):**  $\approx 83.8\%$
- **Sensitivity (Czułość):**  $\frac{TP}{TP+FN} \approx 78.4\%$
- **Specificity (Swoistość):**  $\frac{TN}{TN+FP} \approx 88.6\%$

# Analiza Modelu Regresji Logistycznej

Przedstawiony raport to wynik regresji logistycznej, która przewiduje prawdopodobieństwo wystąpienia zdarzenia TARGET na podstawie danych medycznych.

Najsilniejszymi czynnikami są liczba naczyń krwionośnych oraz wynik testu talowego. Istotny wpływ mają również płeć i asymptomatyczny ból klatki piersiowej.

Zmienne takie jak cholesterol czy ciśnienie krwi okazały się nieistotne ( $p > 0.05$ ).

```
Call:
glm(formula = TARGET ~ ., family = "binomial", data = train_data)

Coefficients:
              Estimate Std. Error z value Pr(>|z|)
(Intercept) -5.414864   4.338824  -1.248  0.212030
Age          -0.060784   0.035346  -1.720  0.085486 .
Sex1         2.759481   0.921273   2.995  0.002742 **
`Chest pain type`2  2.775252   1.297121   2.140  0.032391 *
`Chest pain type`3  1.007259   1.142377   0.882  0.377927
`Chest pain type`4  3.228971   1.179906   2.737  0.006207 **
BP           0.010185   0.016487   0.618  0.536718
Cholesterol    0.008606   0.005573   1.544  0.122548
`FBS over 120`1   -0.035335   0.783837  -0.045  0.964044
`EKG results`1    3.386498   4.164703   0.813  0.416136
`EKG results`2    0.543392   0.524283   1.036  0.299993
`Max HR`         -0.021012   0.014825  -1.417  0.156382
`Exercise angina`1 0.618007   0.616836   1.002  0.316393
`ST depression`   0.504384   0.307390   1.641  0.100827
`Slope of ST`2    1.011192   0.673736   1.501  0.133389
`Slope of ST`3    0.479473   1.075415   0.446  0.655706
`Number of vessels fluoro`1 2.576759   0.674462   3.820  0.000133 ***
`Number of vessels fluoro`2 3.854031   1.058561   3.641  0.000272 ***
`Number of vessels fluoro`3 4.083822   1.310385   3.117  0.001830 **
Thallium6        -0.485887   1.211733  -0.401  0.688431
Thallium7        2.126256   0.585849   3.629  0.000284 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 278.81  on 202  degrees of freedom
Residual deviance: 108.27  on 182  degrees of freedom
AIC: 150.27

Number of Fisher Scoring iterations: 7
```

## Wizualizacja wyników modelu

- **Problem FN (False Negatives):** Model wygenerował 625 błędów typu "przeoczenie choroby". W medycynie jest to kosztowniejszy błąd niż fałszywy alarm.
- **Konserwatyzm modelu:** Wyższa swoistość (88.6%) niż czułość (78.4%) sugeruje, że model jest ostrożny w diagnozowaniu choroby.
- **Rekomendacja:** Dla poprawy bezpieczeństwa pacjentów sugeruje się obniżenie progu klasyfikacji (*threshold*) z 0.5 na 0.4, co zwiększy czułość modelu kosztem większej liczby fałszywych alarmów.

- 1 Zmienne kliniczne (EKG, tętno, ból w klatce) pozwalają na skuteczną predykcję chorób serca
- 2 Zastosowanie symulacji Monte Carlo pozwoliło na rzetelną ocenę modelu, eliminując przypadkowość pojedynczego testu
- 3 Model osiąga wysoką dokładność ogólną, ale wymaga kalibracji w celu zwiększenia czułości (zmniejszenia liczby przeoczonych chorych), co jest kluczowe w diagnostyce medycznej